

Architecture Decision Records

ADR-001: Yandex Cloud как облачный провайдер

Статус: Принято

Решение: Использовать Yandex Cloud (Object Storage, Managed Kafka, Compute Cloud)

Причины:

- Единая экосистема с API-совместимостью S3
- Управляемый Kafka без настройки инфраструктуры
- Российский регион с низкой задержкой

ADR-002: Data Lake на S3 с Parquet

Статус: Принято

Решение: Хранить данные в S3-совместимом Object Storage в формате Parquet

Причины:

- Колоночное хранение = быстрые аналитические запросы
- Сжатие данных экономит до 80% места
- Совместимость с Spark/Pandas/ClickHouse

ADR-003: Airflow для оркестрации

Статус: Принято

Решение: Apache Airflow как ETL-оркестратор

Причины:

- DAG как код (Python) для всех трансформаций
- Retry-политики и мониторинг из коробки

- Де-факто стандарт в индустрии

ADR-004: Слои Bronze/Silver/Gold

Статус: Принято

Решение: Три слоя данных: Raw → Bronze → Silver → Gold

Причины:

- Bronze: сырые данные без изменений
- Silver: очищенные, дедуплицированные
- Gold: агрегаты и признаки для ML

ADR-005: Kafka для real-time

Статус: Принято

Решение: Managed Kafka + Python-сервисы для обработки событий

Причины:

- Гарантированная доставка событий
- Поточковая агрегация в скользящие окна
- ClickHouse для хранения и аналитики

ADR-006: Cube.js для семантического слоя

Статус: Принято

Решение: Cube.js как семантический слой между данными и визуализацией

Причины:

- Единые метрики и измерения для всех потребителей
- API-first подход для embedded-аналитики
- Поддержка ClickHouse из коробки