

Университетская дата-платформа

Архитектура

Сырые данные → S3 Raw → S3 Bronze → S3 Silver → S3 Gold → ClickHouse → Cube.js → Streamlit

API LMS / CSV → S3 Raw

Kafka Events → ClickHouse (real-time)

Компоненты

Компонент	Технология	Назначение
Оркестрация	Airflow 2.7	ETL/ELT пайплайны
Хранилище	Yandex S3	Data Lake (4 слоя)
Стриминг	Managed Kafka 3.7	Real-time события
Аналитика	ClickHouse 23.3	Колоночная БД
Семантика	Cube.js 1.6	API для метрик
Дашборд	Streamlit	Embedded Analytics
Инфраструктура	Terraform	IaC
Валидация	Great Expectations	Качество данных

Быстрый старт

1. Инфраструктура

```
cd terraform
terraform init
terraform apply
```

2. Запуск Airflow

```
ssh ubuntu@<IP>
cd ~/airflow
docker-compose up -d
```

3. Запуск потоковой обработки

```
python3 kafka_producer_full.py &
python3 kafka_aggregator.py
```

4. Запуск Cube.js

```
cd cubejs-university
npm run dev
```

5. Запуск дашборда

```
cd dashboard
streamlit run app.py
```

Доступы

- Airflow: <http://:8080> (admin/admin)
- Cube.js: <http://localhost:4000>
- ClickHouse: <http://:8123>
- Streamlit: <http://localhost:8501>

Мониторинг

- Логи Airflow: `/opt/airflow/logs/`
- Kafka метрики: Yandex Cloud Console
- ClickHouse метрики: `system.metrics` table